PREDMET: Analiza i vizualizacija podataka

Analiza faktora koji utiču na zadovoljstvo životom u jednoj zemlji

###The World Happiness Report-je svetski izveštaj koji rangira 156 zemalja po tome koliko njihovi gradjani smatraju sebe srećnim. Ta lista se sastavlja tako što uzorci stanovnika iz svake zemalje ocenama od 0 do 10 odgovoraju na pitanja o kvalitetu svog života. Kao potencijalni faktori koji tome doprinose uzimaju se u obzir vrednost GDP po stanovniku, očekivano trajanje života, velikodušnost (ispitanici odgovaruju na pitanje da li doniraju novac u dobrotvorne svrhe), društvena podrška (da li imaju podršku od strane porodice ili prijatelja), osećaj slobode i prisustvo korupcije u zemlji (percepcija ispitanika o postojanju korupcije).

#Istraživanje obuhvata godišnji uzorak od 1.000 ljudi, a ukoliko je neka zemlja imala istraživanja svake godine, tada je veličina uzorka 3.000 ljudi.

#Podaci se odnose na izveštaj iz 2020. godine.

Baza je dostupna na https://www.kaggle.com/mathurinache/world-happiness-report?select=2020.csv

```
#Potrebni paketi
library(dplyr)
library(tidyr)
library(ggplot2)
```

Učitavanje baze

```
WHR_data<-read.csv("Data/WorldHappinessReport2020.csv", stringsAsFactors = FALSE)
glimpse(WHR_data20)</pre>
```

```
> glimpse(WHR_data)
Rows: 153
Columns: 20
$ Country.name
"Norway", "Netherlands", "Sweden",...
$ Regional.indicator
ope", "Western Europe", "Western E...
 Ladder.score
7.3535, 7.2996, 7.2942, 7.2375, 7....
 Standard.error.of.ladder.score
0.03483738, 0.02779175, 0.03623420...
  upperwhisker
 7.503372, 7.424519, 7.376953, 7....
lowerwhisker
  7.394428, 7.282481, 7.222248, 7....
  Logged.GDP.per.capita
87804, 10.812712, 10.758794, 10.50...
 Social.support
       0.9391388, 0.9263112, 0.949...
  Healthy.life.expectancy
  72.30092, 72.60077, 73.20263, 73...
Freedom.to.make.life.choices
57503, 0.9085478, 0.9391442, 0.936...
$ Generosity
19, 0.134532630, 0.207612440, 0.1...
$ Perceptions.of.corruption
32182, 0.3647171, 0.2508802, 0.221...
  Ladder.score.in.Dystopia
 1.972317, 1.972317, 1.972317, 1....
Explained.by..Log.GDP.per.capita
42073, 1.3389463, 1.3222352, 1.242...
 Explained.by..Social.support
 1.463646, 1.433348, 1.487218, 1....
```

```
<chr> "Finland", "Denmark", "Switzerland", "Iceland",
<chr> "Western Europe", "Western Europe", "Western Eur
<db7> 7.8087, 7.6456, 7.5599, 7.5045, 7.4880, 7.4489,
<db7> 0.03115630, 0.03349229, 0.03501417, 0.05961586,
<db7> 7.869766, 7.711245, 7.628528, 7.621347, 7.556281
<db7> 7.747634, 7.579955, 7.491272, 7.387653, 7.419719
<db7> 10.639267, 10.774001, 10.979933, 10.772559, 11.0
<db7> 0.9543297, 0.9559908, 0.9428466, 0.9746696, 0.95
<db7> 71.90083, 72.40250, 74.10245, 73.00000, 73.20078
<db7> 0.9491722, 0.9514443, 0.9213367, 0.9488919, 0.95
<db7> 0.059482019, 0.066201776, 0.105911039, 0.2469442
<db7> 0.1954446, 0.1684895, 0.3037284, 0.7117097, 0.26
<db7> 1.972317, 1.972317, 1.972317, 1.972317, 1.972317
<db7> 1.2851895, 1.3269485, 1.3907742, 1.3265016, 1.42
<db7> 1.499526, 1.503449, 1.472403, 1.547567, 1.495173
```

```
$ Explained.by..Healthy.life.expectancy 80719, 0.9756753, 0.9864705, 1.008... $ Explained.by..Freedom.to.make.life.choices 02009, 0.6136265, 0.6502977, 0.646... $ Explained.by..Generosity $ <db/>
0.28798509, 0.33631757, 0.27282789... $ Explained.by..Perceptions.of.corruption 72, 0.434100568, 0.368569762, 0.44... $ Dystopia...residual $ <db/>
82663, 2.3521171, 2.2462993, 2.128... $ Baze sadrzi podatke za 153 zemlje $ <db/>
4db/> 0.9612714, 0.9793326, 1.0405332, 1.0008434, 1.00 $ <db/>
$ (db/> 0.6650399, 0.6289545, 0.6619807, 0.67 $ <db/>
$ (db/> 0.15967044, 0.24279340, 0.26905575, 0.36233023, $ <db/>
$ (db/> 0.477857262, 0.495260328, 0.407945901, 0.1445407 $ <db/>
$ (2db/> 0.477857262, 0.495260328, 0.407945901, 0.1445407 $ <db/>
```

#Priprema podataka za analizu

Provera nedostajućih vrednosti

```
sum(is.na(WHR_data))
> sum(is.na(WHR_data))
[1] 0
```

Nema NA

Odabir varijabli koje cemo uključiti u istraživanje i preimenovanje kolona radi lakšeg snalaženja

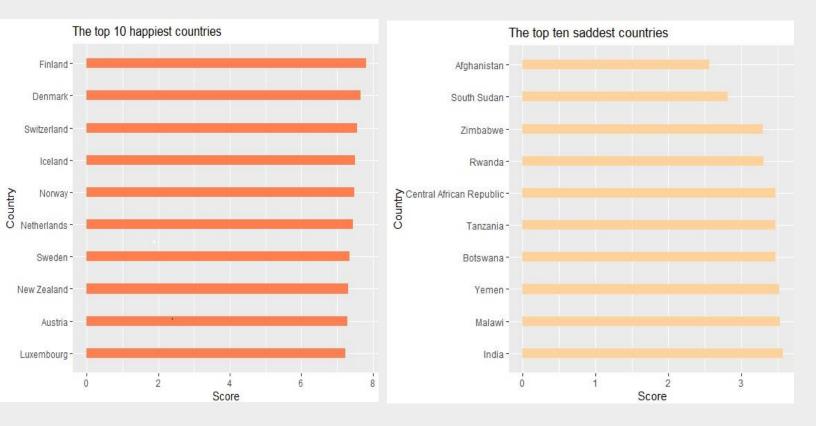
Sada baza izgleda ovako

glimpse(WHR_data20)

```
###Eksplorativna analiza
```

Deset 'najsrećnijih' zemalja

Deset 'najnesrećnijih' zemalja



Kako je Srbija rangirana i kako su gradjani Srbije ocenili kvalitet života u zemlji?

```
WHR_data20[WHR_data20$Country == "Serbia",c(1,3) ]
> WHR_data20[WHR_data20$Country == "Serbia",c(1,3) ]
    Country Happ_Score
64 Serbia 5.7782
```

#Od 153 zemlje, Srbija se nalazi na 64. mestu. Na skali sreće od 1 do 10, Srbija je imala ocenu 5,78.

Srbija u odnosu na zemlje u okruženju

```
WHR data20[WHR data20$Country %in%
              c('Serbia','Hungary','Romania','Bulgaria','Albania','Montenegro',
                   'Bosnia and Herzegovina', 'Croatia', 'Slovenia'), c(1,3)]
> WHR_data20[WHR_data20$Country %in%
                c('Serbia','Hungary','Romania','Bulgaria','Albania','Montenegro',
'Bosnia and Herzegovina','Croatia','Slovenia'), c(1,3)]
+
                      Country Happ_Score
33
                     Slovenia
                                    6.3634
47
                      Romania
                                    6.1237
53
                                    6.0004
                      Hungary
64
                                    5.7782
                       Serbia
69
72
    Bosnia and Herzegovina
                                    5.6741
                                    5.5461
                   Montenegro
79
                                    5.5047
                      Croatia
96
                                    5.1015
                     Bulgaria
                                    4.8827
105
                      Albania
```

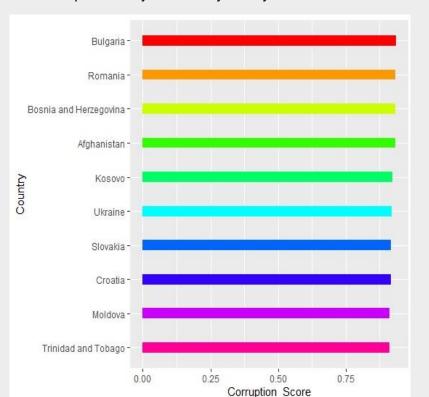
U odnosu na zemlje regiona, Srbija je 'srećnija' od BiH (69), Crne Gore (72), Hrvatske (79), Bugarske (96) i Albanije (105), a ispred nje se nalaze Slovenija (33. mesto), Rumunija (47), Madjarska (53).

Ocekivani životni vek u Srbiji

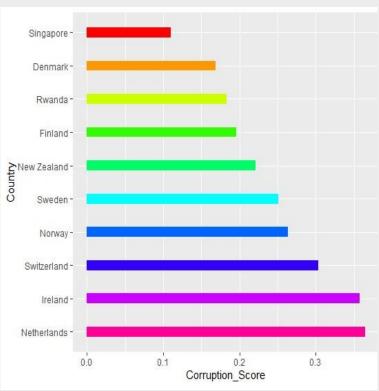
Najkorumiranije zemlje na osnovu ocene njihovih gradjana

Najmanje korumiranije zemlje na osnovu ocene njihovih gradjana

Graficki prikaz 'Najkorumiranije zemlje '



'Najmanje korumiranije zemlje'



Istraživačka pitanja

- # Da li postoji statistički značajna veza izmedju sreće i
- -vrednosti GDP-a po glavi stanovnika (GDP per capita),
- -podrske porodice i prijatelja (Social.support),
- -očekivanog trajanja zivota (life expectancy),
- -velikodušnosti (Generosity) i
- -prisustva korupcije u društvu (Corruption).
- # Odgovore na ova pitanja cemo dobiti primenom korelacije, a primenom metoda linerne regresije utvrdicemo koliko su ove varijable pogodne za predvinjanje zadovoljstva kvalitetom zivota (ocene sreće).
- #Pre sprovodjenja ovih tehnika, potrebno je utvrditi da li varijable podležu normalnoj distribuciji ili ne, ukoliko je to slucaj koristimo Pearsonov koeficijent korelacije (normalna raspodela), u suprotnom Spirmanov koef.
- #Pomocu Shapiro-Wilk testa utvrdjujemo da li varijabe podeležu normalnoj distribuciji ili ne
- H₀..podleze normalnoj distribuciji, ukoliko je p>0.01, prihvatamo H₀, u sprotnom odbacujemo u korist H1
- H₁..ne podleze normalnoj distribuciji

```
shapiro.test(WHR data20$Happ Score)
> shapiro.test(WHR_data20$Happ_Score)
        Shapiro-Wilk normality test
data: WHR_data20$Happ_Score
W = 0.98899, p-value = 0.2742
# podleze normalnoj distribuciji
shapiro.test(WHR data20$GDP)
> shapiro.test(WHR_data20$GDP)
        Shapiro-Wilk normality test
data: WHR_data20$GDP
W = 0.9624, p-value = 0.000352
#ne podleze normalnoj distribuciji
shapiro.test (WHR data20$Social.support)
> shapiro.test(WHR_data20$Social.support)
        Shapiro-Wilk normality test
data: WHR_data20$Social.support
W = 0.9048\overline{6}, p-value = 1.958e-08
#ne podleze normalnoj distribuciji
shapiro.test(WHR data20$Life exp)
> shapiro.test(WHR_data20$Life_exp)
        Shapiro-Wilk normality test
data: WHR_data20$Life_exp
W = 0.95457, p-value = 6.744e-05
#ne podleze normalnoj distribuciji
shapiro.test(WHR data20$Generosity)
> shapiro.test(WHR_data20$Generosity)
        Shapiro-Wilk normality test
data: WHR_data20$Generosity
W = 0.95663, p-value = 0.0001029
#ne podleze normalnoj distribuciji
shapiro.test(WHR data20$Corruption)
> shapiro.test(WHR_data20$Corruption)
        Shapiro-Wilk normality test
data: WHR_data20$Corruption
W = 0.82274, p-value = 2.478e-12
#ne podleze normalnoj distribuciji
```

Samo jedna varijabla podleze normalnoj distribuciji (ocena srece), a sve ostale odstupaju od normalne raspodele,

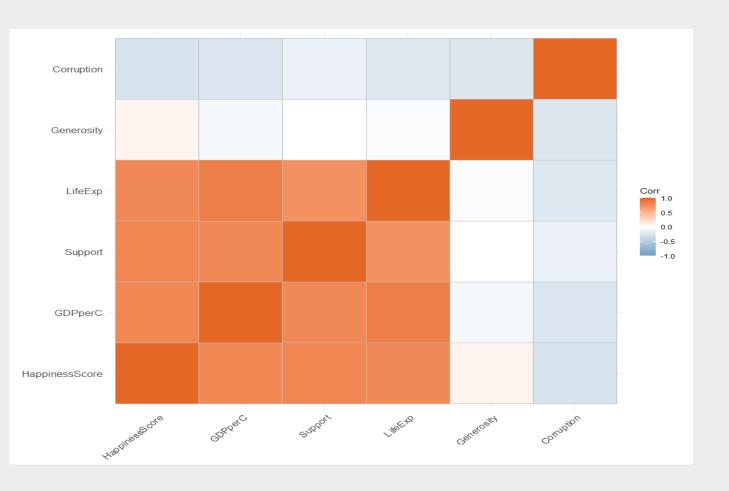
koristimo Spirmanov koef. korelacije.

Korelacija

```
library("Hmisc")
WHR corr <- data.frame (WHR data20$Happ Score, WHR data20$GDP perCapita,
                       WHR data20$Social.support, WHR data20$Life exp,
                                 WHR data20$Generosity, WHR data20$Corruption)
rcorr(as.matrix(WHR corr), type = c("spearman"))
            WHR_data20.Happ_Score WHR_data20.GDP_perCapita WHR_data20.Social.support WHR_data20.Lif
e_exp
                                                                       0.79
WHR_data20.Happ_Score
                                             1.00
                                                                                                   0.80
0.78
                                             0.79
                                                                       1.00
                                                                                                   0.78
WHR_data20.GDP_perCapita
0.85
WHR_data20.Social.support
                                             0.80
                                                                       0.78
                                                                                                   1.00
0.73
WHR_data20.Life_exp
                                                                       0.85
                                                                                                   0.73
                                             0.78
1.00
WHR_data20.Generosity
                                             0.07
                                                                      -0.07
                                                                                                   0.00
-0.04
WHR_data20.Corruption -0.23
                                            -0.28
                                                                      -0.26
                                                                                                  -0.14
                           WHR_data20.Generosity WHR_data20.Corruption
WHR_data20.Happ_Score
                                             0.07
                                                                   -0.28
WHR_data20.GDP_perCapita
                                            -0.07
                                                                   -0.26
                                                                   -0.14
WHR_data20.Social.support
                                             0.00
WHR_data20.Life_exp
                                            -0.04
                                                                   -0.23
                                             1.00
WHR_data20.Generosity
                                                                   -0.25
WHR_data20.Corruption
                                                                    1.00
                                            -0.25
n = 153
                           WHR_data20.Happ_Score WHR_data20.GDP_perCapita WHR_data20.Social.support
WHR_data20.Life_exp
                                                  0.0000
                                                                             0.0000
WHR_data20.Happ_Score
0.0000
                                                                             0.0000
WHR_data20.GDP_perCapita 0.0000
0.0000
                                                  0.0000
WHR_data20.Social.support 0.0000
0.0000
WHR_data20.Life_exp
                           0.0000
                                                  0.0000
                                                                             0.0000
WHR_data20.Generosity
                           0.3600
                                                  0.3804
                                                                             0.9617
0.6244
WHR_data20.Corruption
                           0.0005
                                                  0.0014
                                                                             0.0781
0.0051
                           WHR_data20.Generosity WHR_data20.Corruption
WHR_data20.Happ_Score
                           0.3600
                                                  0.0005
                           0.3804
WHR_data20.GDP_perCapita
                                                  0.0014
WHR_data20.Social.support 0.9617
                                                  0.0781
WHR_data20.Life_exp
                           0.6244
                                                  0.0051
WHR_data20.Generosity
                                                  0.0022
WHR_data20.Corruption
                           0.0022
```

Vizualizacija korelacije

```
names (WHR_corr) = c('HappinessScore', 'GDPperC', 'Support', 'LifeExp', 'Generosity', 'Corruption')
WHR_corrplot <-cor(WHR_corr, method = "spearman")
library(ggcorrplot)
ggcorrplot(WHR_corrplot, method = "square", colors = c("#6D9EC1", "white", "#E46726"))</pre>
```

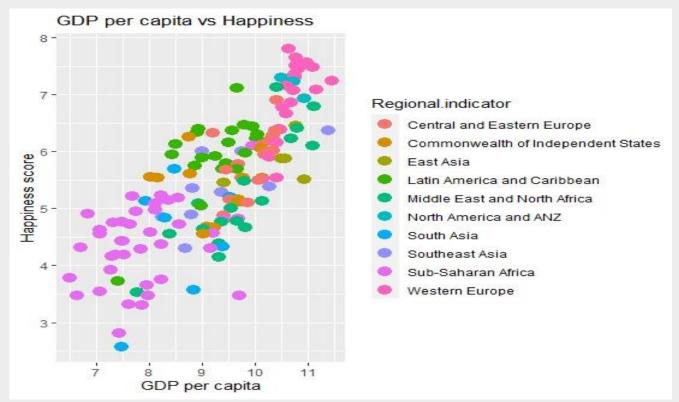


#REZULTATI ANALIZE

- # 1) Da li postoji statistički značajna veza izmedju vrednosti GDP per capita i sreće (kvaliteta života)?
- # p (p=0) vrednost je manja od 0.01, veza je statistički značajna;
- # Koef.korelacije je 0.79 (r=0.79), što znači da postoji pozitivna i jaka veza izmedju ove dve varijable, odnosno sa rastom GDP per capita, raste i zadovoljstvo zivotom tj. ocena sreće i obrnuto.

Grafički prikaz

```
qplot(data=WHR_data20, x=GDP_perCapita,y=Happ_Score,colour=Regional.indicator,size=I(4))+
    labs(title ='GDP per capita vs Happiness', x='GDP per capita', y='Happiness score')
```

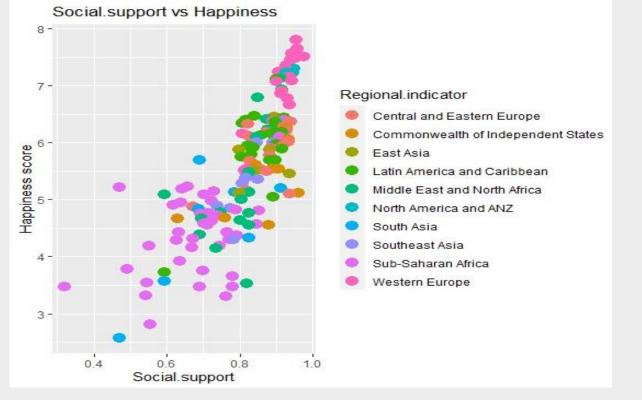


#Na grafiku možemo uočiti da zemlje Zapadne Evrope imaju najveće vrednosti za GDP i nalaze se medju najsrećnijima. *Napomena: Zemlje Zapadne Evrope (*WEOG-Western European and Other States Group-prema klasifikaciji UN, u ovu grupu zemalja ubraju se i zemlje Severne Evrope kao i odredjene zemlje Okeanije(Australija i Nz) i Zapadne Azije (Turska i Izrael)).

- # 2) Da li postoji statisticki znacajna veza izmedju postojanja društvene podrške i sreće?
- # p (p=0) vrednost je manja od 0.01, veza je statistički značajna;
- # Koef.korelacije je 0.80 (r=0.80), što znači da postoji pozitivna i jaka veza izmedju ove dve varijable, odnosno sa rastom društvene podrske, raste i zadovoljstvo zivotom tj. ocena sreće i obrnuto.

Grafički prikaz

```
qplot(data=WHR_data20, x=Social.support,y=Happ_Score,colour=Regional.indicator,size=I(4))+
labs(title ='Social.support vs Happiness', x='Social.support', y='Happiness score')
```



- # 3) Da li postoji statistički značajna veza izmedju dužine očekivanog životnog veka i sreće?
- # p (p=0) vrednost je manja od 0.01, veza je statistički značajna;
- # Koef.korelacije je 0.78 (r=0.78), što znači da postoji pozitivna i jaka veza izmedju ove dve varijable, odnosno sa rastom drustvene podrske, raste i zadovoljstvo zivotom tj. ocena sreće i obrnuto.

Grafički prikaz

```
qplot(data=WHR_data20, x=Life_exp,y=Happ_Score,colour=Regional.indicator,size=I(4))+
labs(title ='Life expectancy vs Happiness', x='Life expectancy', y='Happiness score')
```

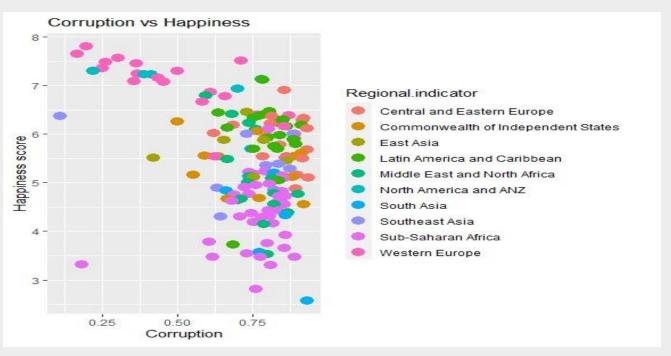


#4) Da li postoji statistički značajna veza izmedju velikodušnosti i sreće?

Postoji pozitivna i slaba veza izmedju ove dve varijable (r=0.07), p=0.36, p> 0,01, odatle sledi da ova veza statistički nije značajna!

- #5) Da li postoji statistički značajna veza izmedju sreće i prisustva korupcije u društvu (prema percepciji gradjana)?
- # p (p=0) vrednost je manja od 0.01, veza je statistički značajna;
- # Koef.korelacije je -0.28 (r=-0.28), što znači da postoji negativna i slaba veza izmedju ove dve varijable, odnosno ako nivo korupcije raste, nivo sreće se smanjuje i obrnuto.

```
qplot(data=WHR_data20, x=Corruption,y=Happ_Score,colour=Regional.indicator,size=I(4))+
labs(title = 'Corruption vs Happiness', x='Corruption', y='Happiness score')
```



Utvrdjeno je da postoji pozitivna korelacija između varijable nivoa sreće i varijabli GDP-a po stanovniku, postojanja društvene podrške, dužine očekivanog životnog veka i negativna korelacija između varijable nivoa sreće i postojanja korupcije u društvu, dok veza izmedju izmedju velikodušnosti i sreće nije statistički značajna.

Najjača je korelacija sa postojanjem društvene podrške (r=0,80), zatim sa GDP per capita (r=0,79) i dužine očekivanog životnog veka (r=0,78).

```
#Regresioni modeli:
```

```
# Prvi model – ( sve varijable izmedju kojih postoji statistički značajna korelacija)
Model 1 <- lm(WHR data20$Happ Score ~ WHR data20$GDP perCapita + WHR data20$Social.support +
                    WHR data20$Life exp+WHR data20$Corruption)
summary(Model 1)
> summary(Model_1)
call:
lm(formula = WHR_data20$Happ_Score ~ WHR_data20$GDP_perCapita +
    WHR_data20$Social.support + WHR_data20$Life_exp + WHR_data20$Corruption)
Residuals:
     Min
                10
                     Median
                                           Max
-1.70267 -0.38014
                    0.06589
                             0.37730
                                      1.64494
Coefficients:
                           Estimate Std. Error t value Pr(>|t|)
(Intercept)
                           -0.79994
                                        0.59207
                                                 -1.351 0.178729
                                                  2.242 0.026428 *
                            0.19055
WHR_data20$GDP_perCapita
                                        0.08498
                            3.49545
                                        0.66525
                                                  5.254 5.09e-07 ***
WHR_data20$Social.support
                                                  2.880 0.004561 **
                            0.03909
                                        0.01357
WHR_data20$Life_exp
                                                 -3.848 0.000177 ***
WHR_data20$Corruption
                           -1.15109
                                        0.29917
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '1
Residual standard error: 0.5981 on 148 degrees of freedom
Multiple R-squared: 0.7185, Adjusted R-squared: 0.7109
F-statistic: 94.43 on 4 and 148 DF, p-value: < 2.2e-16
# Prvi model je prilično dobar, objašnjava 72 % varjabiliteta zadovoljstva kvalitom života (uk. ocene sreće)
\# r^2 = 0.72, p < 0.01
# Drugi model (varijable izmedju kojih je najjača korelacija)
Model 2 <- lm (WHR data20$Happ Score ~ WHR data20$GDP perCapita + WHR data20$Social.support +
                WHR data20$Life exp)
summary (Model 2)
> summary(Model_2)
call:
lm(formula = WHR_data20$Happ_Score ~ WHR_data20$GDP_perCapita +
    WHR_data20$Social.support + WHR_data20$Life_exp)
Residuals:
                10
                     Median
     Μin
-1.73169 -0.44349 -0.00185 0.49128
Coefficients:
                           Estimate Std. Error t value Pr(>|t|)
                           -2.29961
                                                 -4.936 2.11e-06 ***
(Intercept)
                                        0.46586
                                                  2.594 0.010439 *
WHR_data20$GDP_perCapita
                            0.22882
                                        0.08822
                                                  4.601 8.94e-06 ***
WHR_data20$Social.support
                                        0.68987
                            3.17379
                                                  3.416 0.000819 ***
WHR_data20$Life_exp
                            0.04778
                                        0.01399
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.6252 on 149 degrees of freedom
Multiple R-squared: 0.6903,
                               Adjusted R-squared: 0.6841
```

F-statistic: 110.7 on 3 and 149 DF, p-value: < 2.2e-16

```
# Drugi model je takodje dobar objašnjava 69 % varjabiliteta zadovoljstva kvalitom života (uk. ocene sreće)
\# r^2 = 0.69, p < 0.01
# Treći model
Model 3 <- lm(WHR data20$Happ Score ~ WHR_data20$GDP_perCapita)
summary(Model 3)
> summary(Mode1_3)
lm(formula = WHR_data20$Happ_Score ~ WHR_data20$GDP_perCapita)
Residuals:
                 1Q
     Min
                      Median
-2.29256 -0.52524 0.02843 0.57109 1.38802
Coefficients:
                            Estimate Std. Error t value Pr(>|t|)
                                          0.44586 -2.688 0.00799 **
(Intercept)
                            -1.19865
WHR_data20$GDP_perCapita 0.71774
                                          0.04757 15.088 < 2e-16 ***
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' '1
Residual standard error: 0.7047 on 151 degrees of freedom
Multiple R-squared: 0.6012, Adjusted R-squared: 0.5986 F-statistic: 227.6 on 1 and 151 DF, p-value: < 2.2e-16
# Ovaj model je takodje dobar jer objašnjava 60 % varjabiliteta ukupne ocene sreće sa samo jednom varijablom
\# r^2 = 0.60, p < 0.01
Model 4 <- lm(WHR data20$Happ Score ~ WHR data20$Social.support)
summary(Model 4)
> summary(Mode1_4)
lm(formula = WHR_data20$Happ_Score ~ WHR_data20$Social.support)
Residuals:
                      Median
-2.01071 -0.3826Ì -0.04146  0.4645Š
Coefficients:
                             Estimate Std. Error t value Pr(>|t|)
(Intercept)
                               -0.1926
                                            0.3925
                                                    -0.491
                                                                 0.624
                                                               <2e-16 ***
WHR_data20$Social.support
                              7.0059
                                            0.4800 14.596
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.7187 on 151 degrees of freedom Multiple R-squared: 0.5852, Adjusted R-squared: 0.5825
```

Ovaj model je takodje dobar jer objašnjava 58 % varjabiliteta ukupne ocene sreće sa samo jednom varijablom # r^2 = 0,58, p < 0.01

#Prvi model je najbolji jer objašnjava najveći procenat varijabiteta ukupne ocene sreće.

F-statistic: 213.1 on 1 and 151 DF, p-value: < 2.2e-16